

BLM4522

AĞ TABANLI PARALEL DAĞITIM SİSTEMLERİ

VİZE PROJELERİ

Ad Soyad: Emre Süt Öğrenci Numarası: 22290048

GitHub Repo Linki: <https://github.com/emresut/Ag-Tabanli-Paralel-Dagitim-Sistemleri>

İki proje de tek reponun içinde bulunmaktadır.

İÇİNDEKİLER

Proje 5 - Veri Temizleme ve ETL Süreçleri Tasarımı	1
1 - GİRİŞ	1
2 - VERİ SETİ	1
3 - ETL SÜRECİ (Extract, Transform, Load)	2
3.1. Veri Alma	2
3.2. Veriyi Bozma	2
3.3. Veriyi Temizleme ve Dönüştürme	3
3.4. Temiz Veriyi Aktarma	3
4 - VERİ KALİTESİ ANALİZİ	4
5 - SONUÇ VE GENEL DEĞERLENDİRME	4

PROJE 5 - Veri Temizleme ve ETL Süreçleri Tasarımı

1) GİRİŞ

Bu projede, gerçek hayatta sıkça karşılaşılan kirli verilerin temizlenmesi ve işlenmesi amacıyla bir ETL (Extract, Transform, Load) süreci gerçekleştirilmiştir. Veri analizi ve veri bilimi çalışmalarında, kullanılan verinin kalitesi elde edilecek sonuçların doğruluğunu doğrudan etkilediğinden, ETL süreci kritik bir öneme sahiptir.

Proje kapsamında Kaggle platformundan elde edilen bir çalışan(employee) veri seti kullanılmıştır. Bu veri seti önce veritabanına aktarılmış, ardından bilinçli olarak hatalar eklenerek “messy” (bozulmuş) hale getirilmiş ve son aşamada çeşitli SQL işlemleri ile temizlenerek “clean” (temiz) bir tabloya dönüştürülmüştür.

Veri seti linki: <https://www.kaggle.com/datasets/desolution01/messy-employee-dataset?resource=download>

Tüm süreçte MSSQL kullanılmıştır, araç olarak SQL Server Management Studio kullanılmıştır.

2) VERİ SETİ

Projede kullanılan veri seti Kaggle platformundan elde edilen “Messy Employee Dataset” adlı veri setidir. Bu veri seti fazlaca çalışan kaydı içermektedir.

Veri setinde bulunan sütunlar şu şekildedir: *Employee_ID, First_Name, Last_Name, Age, Department_Region, Status, Join_Date, Salary, Email, Phone, Performance_Score, Remote_Work*

Bu veri seti başlangıçta temiz bir yapıda sayılabilir ancak proje kapsamında veri temizleme işlemlerini gösterebilmek için üzerinde kasıtlı olarak çeşitli bozulmalar gerçekleştirilecektir. Raw veri setinde sadece yaş(age) kısmında boşluklar vardır.

Aşağıda örnek olması amacıyla raw veri setinin ilk 10 satırı görsel olarak verilmiştir.

	Employee_ID	First_Name	Last_Name	Age	Department_Region	Status	Join_Date	Salary	Email	Phone	Performance_Score	Remote_Work
1	EMP1000	Bob	Davis	25	DevOps-California	Active	4/2/2021	59767.65	bob.davis@example.com	-1651623197	Average	TRUE
2	EMP1001	Bob	Brown	NULL	Finance-Texas	Active	7/10/2020	65304.66	bob.brown@example.com	-1898471390	Excellent	TRUE
3	EMP1002	Alice	Jones	NULL	Admin-Nevada	Pending	12/7/2023	88145.9	alice.jones@example.com	-5596363211	Good	TRUE
4	EMP1003	Eva	Davis	25	Admin-Nevada	Inactive	11/27/2021	69450.99	eva.davis@example.com	-3476490784	Good	TRUE
5	EMP1004	Frank	Williams	25	Cloud Tech-Florida	Active	1/5/2022	109324.61	frank.williams@example.com	-1586734256	Poor	FALSE
6	EMP1005	Alice	Garcia	40	Sales-Texas	Inactive	6/10/2020	88642.84	alice.garcia@example.com	-5409003485	Good	FALSE
7	EMP1006	Frank	Jones	NULL	Admin-Nevada	Active	4/3/2020	96288.43	frank.jones@example.com	-4518376063	Good	FALSE
8	EMP1007	Bob	Jones	30	Cloud Tech-Florida	Inactive	7/17/2022	94497.91	bob.jones@example.com	-4134327559	Average	TRUE
9	EMP1008	Frank	Davis	35	Admin-Nevada	Inactive	12/8/2023	115565.82	frank.davis@example.com	-4177656123	Excellent	TRUE
10	EMP1009	Charlie	Johnson	NULL	DevOps-New York	Active	8/4/2022	76561.88	charlie.johnson@example.com	-8156985699	Excellent	TRUE

3) ETL SÜRECİ (Extract, Transform, Load)

3.1. Veri Alma

Veri seti CSV formatında Kaggle üzerinden indirilmiş ve server içerisine import edilerek raw_employee_table tablosuna aktarılmıştır. Bu işlem sırasında SQL Server'ın Import Wizard aracı kullanılmıştır. Sonrasında raw veri setinin bozulmaması için raw_employee_table aynen messy_employee_table adlı bir table'ın içerisine kopyalanmıştır. Veriyi bozma işlemi messy_employee_table üzerinden yapılacaktır.

3.2. Veriyi Bozma

Bu aşamada, veri temizleme sürecini simüle edebilmek için veri bilinçli olarak bozulmuştur. Bu işlem 02_disrupt_data.sql scripti ile gerçekleştirilmiştir.

Bu script içerisinde bazı age alanlarına **"unknown"** değeri atanmıştır, bazı email alanları **"invalid_email"** olarak değiştirilmiştir, kimi first_name'lerde başına ve sonuna bilerek boşluk karakteri konulmuştur, bazı salary(maaş) kısımlarına olması imkansız negatif değer verilmiştir (-5000), kimi yerde phone alanı **"no-phone"** yapılmıştır, Department_Region formatı normal tire olması gerekirken bazı yerlerde **"Admin_Nevada"** gibi alt tirenin olduğu yanlış formattaki versiyonlar konulmuştur. Bazı yerlerde Join_Date alanına **"not_a_date"** denilmiştir.

Aşağıda örnek olması amacıyla messy_employee_table tablosunun ilk 30 satırı görsel olarak verilmiştir.

	Employee_ID	First_Name	Last_Name	Age	Department_Region	Status	Join_Date	Salary	Email	Phone	Performance_Score	Remote_Work
1	EMP1000	Bob	Davis	25	DevOps-California	Active	4/2/2021	59767.65	bob.davis@example.com	-1651623197	Average	TRUE
2	EMP1001	Bob	Brown	NULL	Admin_Nevada	Active	7/10/2020	65304.66	bob.brown@example.com	-1898471390	Excellent	TRUE
3	EMP1002	Alice	Jones	NULL	Admin-Nevada	Pending	12/7/2023	88145.9	alice.jones@example.com	-5596363211	Good	TRUE
4	EMP1003	Eva	Davis	25	Admin-Nevada	Inactive	not_a_date	69450.99	invalid_email	-3476490784	Good	TRUE
5	EMP1004	Frank	Williams	25	Cloud Tech-Florida	Active	1/5/2022	109324.61	frank.williams@example.com	-1586734256	Poor	FALSE
6	EMP1005	Alice	Garcia	unknown	Sales-Texas	Inactive	6/10/2020	88642.84	alice.garcia@example.com	-5409003485	Good	FALSE
7	EMP1006	Frank	Jones	NULL	Admin-Nevada	Active	4/3/2020	96288.43	frank.jones@example.com	-4518376063	Good	FALSE
8	EMP1007	Bob	Jones	30	Cloud Tech-Florida	Inactive	7/17/2022	-5000	bob.jones@example.com	no-phone	Average	TRUE
9	EMP1008	Frank	Davis	35	Admin-Nevada	Inactive	12/8/2023	115565.82	frank.davis@example.com	-4177656123	Excellent	TRUE
10	EMP1009	Charlie	Johnson	NULL	DevOps-New York	Active	8/4/2022	76561.88	charlie.johnson@example.com	-8156985699	Excellent	TRUE
11	EMP1010	David	Williams	35	Cloud Tech-New York	Active	7/6/2024	72081.71	david.williams@example.com	-2720634590	Average	FALSE
12	EMP1011	David	Davis	NULL	Admin_Nevada	Active	9/4/2023	84946.19	david.davis@example.com	-1238296576	Poor	TRUE
13	EMP1012	Heidi	Williams	30	HR-New York	Active	3/5/2024	89295.77	heidi.williams@example.com	-2429543164	Excellent	FALSE
14	EMP1013	Grace	Williams	NULL	Finance-California	Active	not_a_date	85666.84	invalid_email	-2669300892	Good	FALSE
15	EMP1014	Alice	Garcia	25	Admin-Nevada	Active	6/10/2024	97633.68	alice.garcia@example.com	-1734206968	Excellent	TRUE
16	EMP1015	Grace	Jones	unknown	Sales-Florida	Pending	5/29/2021	117975.49	grace.jones@example.com	-4215291085	Good	TRUE
17	EMP1016	Alice	Brown	25	DevOps-Illinois	Inactive	4/23/2024	94867.33	alice.brown@example.com	-7713334475	Poor	FALSE
18	EMP1017	Grace	Garcia	30	Finance-Texas	Pending	11/28/2024	-5000	grace.garcia@example.com	no-phone	Average	TRUE
19	EMP1018	Charlie	Garcia	NULL	Cloud Tech-Nevada	Inactive	9/19/2024	94726.46	charlie.garcia@example.com	-2044397358	Excellent	FALSE
20	EMP1019	Charlie	Williams	35	Admin-Illinois	Pending	1/2/2020	91926.12	charlie.williams@example.com	-7107256365	Average	TRUE
21	EMP1020	Bob	Miller	35	HR-New York	Active	5/8/2021	111460.67	bob.miller@example.com	-9411800536	Excellent	TRUE
22	EMP1021	Bob	Jones	40	Admin_Nevada	Active	9/19/2020	96182.56	bob.jones@example.com	-5990048963	Good	FALSE
23	EMP1022	Charlie	Johnson	35	Sales-Illinois	Inactive	3/9/2021	115023.94	charlie.johnson@example.com	-6528092427	Average	TRUE
24	EMP1023	David	Garcia	35	Finance-Nevada	Pending	not_a_date	80667.01	invalid_email	-7572158623	Excellent	FALSE
25	EMP1024	Bob	Brown	30	Admin-Texas	Inactive	2/13/2020	91181.61	bob.brown@example.com	-1502745643	Good	TRUE
26	EMP1025	David	Miller	unknown	Cloud Tech-Nevada	Pending	4/30/2020	66025.92	david.miller@example.com	-9485625727	Average	FALSE
27	EMP1026	Frank	Miller	25	Sales-New York	Inactive	10/2/2023	83979.01	frank.miller@example.com	-7032032073	Average	FALSE
28	EMP1027	Heidi	Johnson	30	Finance-Florida	Active	7/12/2020	-5000	heidi.johnson@example.com	no-phone	Excellent	TRUE
29	EMP1028	Grace	Garcia	40	Finance-Nevada	Active	10/11/2023	95741.88	grace.garcia@example.com	-7712151341	Excellent	FALSE
30	EMP1029	Alice	Brown	40	DevOps-California	Active	5/24/2021	63411.31	alice.brown@example.com	-2849939088	Excellent	TRUE

3.3. Veriyi Temizleme ve Dönüştürme

Bu aşama projenin en kritik kısmıdır, ETL süreçlerindeki en önemli noktalar buradadır. Burası 05_main.sql dosyasında gerçekleştirilmiştir.

Bu script içerisinde, first_name'lerde baştaki ve sondaki boşluklar eğer varsa temizlenmiştir, geçersiz sayısal değerler NULL yapılmıştır, geçersiz tarih formatları kontrol edilmiştir, email'ler gerçekten email formatına uygun mu diye kontrol edilmiştir değilse NULL verilmiştir, Department_Region alanı artık tek bir sütun değil de Department ve Region olmak üzere iki sütun olacak şekilde ayrılmıştır(bu bir veri dönüştürme örneği), Remote_Work alanı TRUE FALSE şeklindeyken bit tipine(1 0) dönüştürülmüştür(burada da bir veri dönüştürme vardır).

Doğruluğu kesin olmayan verilerde tahmin etmek yerine NULL vermenin daha doğru bir yaklaşım olacağı öngörülmüştür. Sonradan içinde NULL olan satırlar silinedebilir, bu bir tercihtir.

Tüm bu işlemler sonucunda veri analize daha uygun hale getirilmiştir.

3.4. Temiz Veriyi Aktarma

Temizleme işlemlerinden sonra veriler clean_employee_table tablosuna aktarılmıştır. Bu yapı sayesinde orijinal veri korunmuş, temiz veri ayrı bir tabloda tutulmuştur. Verilerin doğru hedef tabloya yüklenmesi bölümü de bu şekilde tamamlanmıştır.

Aşağıda örnek olması amacıyla clean_employee_table tablosunun ilk 30 satırı görsel olarak verilmiştir.

	Employee_ID	First_Name	Last_Name	Age	Department	Region	Status	Join_Date	Salary	Email	Phone	Performance_Score	Remote_Work
1	EMP1000	Bob	Davis	25	DevOps	California	Active	2021-04-02	59767.65	bob.davis@example.com	-1651623197	Average	1
2	EMP1001	Bob	Brown	NULL	Admin	Nevada	Active	2020-07-10	65304.66	bob.brown@example.com	-1898471390	Excellent	1
3	EMP1002	Alice	Jones	NULL	Admin	Nevada	Pending	2023-12-07	88145.90	alice.jones@example.com	-5596363211	Good	1
4	EMP1003	Eva	Davis	25	Admin	Nevada	Inactive	NULL	69450.99	NULL	-3476490784	Good	1
5	EMP1004	Frank	Williams	25	Cloud Tech	Florida	Active	2022-01-05	109324.61	frank.williams@example.com	-1586734256	Poor	0
6	EMP1005	Alice	Garcia	NULL	Sales	Texas	Inactive	2020-06-10	88642.84	alice.garcia@example.com	-5409003485	Good	0
7	EMP1006	Frank	Jones	NULL	Admin	Nevada	Active	2020-04-03	96288.43	frank.jones@example.com	-4518376063	Good	0
8	EMP1007	Bob	Jones	30	Cloud Tech	Florida	Inactive	2022-07-17	NULL	bob.jones@example.com	NULL	Average	1
9	EMP1008	Frank	Davis	35	Admin	Nevada	Inactive	2023-12-08	115565.82	frank.davis@example.com	-4177656123	Excellent	1
10	EMP1009	Charlie	Johnson	NULL	DevOps	New York	Active	2022-08-04	76561.88	charlie.johnson@example.com	-8156985699	Excellent	1
11	EMP1010	David	Williams	35	Cloud Tech	New York	Active	2024-07-06	72081.71	david.williams@example.com	-2720634590	Average	0
12	EMP1011	David	Davis	NULL	Admin	Nevada	Active	2023-09-04	84946.19	david.davis@example.com	-1238296576	Poor	1
13	EMP1012	Heidi	Williams	30	HR	New York	Active	2024-03-05	89295.77	heidi.williams@example.com	-2429543164	Excellent	0
14	EMP1013	Grace	Williams	NULL	Finance	California	Active	NULL	85666.84	NULL	-2669300892	Good	0
15	EMP1014	Alice	Garcia	25	Admin	Nevada	Active	2024-06-10	97633.68	alice.garcia@example.com	-1734206968	Excellent	1
16	EMP1015	Grace	Jones	NULL	Sales	Florida	Pending	2021-05-29	117975.49	grace.jones@example.com	-4215291085	Good	1
17	EMP1016	Alice	Brown	25	DevOps	Illinois	Inactive	2024-04-23	94867.33	alice.brown@example.com	-7713334475	Poor	0
18	EMP1017	Grace	Garcia	30	Finance	Texas	Pending	2024-11-28	NULL	grace.garcia@example.com	NULL	Average	1
19	EMP1018	Charlie	Garcia	NULL	Cloud Tech	Nevada	Inactive	2024-09-19	94726.46	charlie.garcia@example.com	-2044397358	Excellent	0
20	EMP1019	Charlie	Williams	35	Admin	Illinois	Pending	2020-01-02	91926.12	charlie.williams@example.com	-7107256365	Average	1
21	EMP1020	Bob	Miller	35	HR	New York	Active	2021-05-08	111460.67	bob.miller@example.com	-9411800536	Excellent	1
22	EMP1021	Bob	Jones	40	Admin	Nevada	Active	2020-09-19	96182.56	bob.jones@example.com	-5990048963	Good	0
23	EMP1022	Charlie	Johnson	35	Sales	Illinois	Inactive	2021-03-09	115023.94	charlie.johnson@example.com	-6528092427	Average	1
24	EMP1023	David	Garcia	35	Finance	Nevada	Pending	NULL	80667.01	NULL	-7572158623	Excellent	0
25	EMP1024	Bob	Brown	30	Admin	Texas	Inactive	2020-02-13	91181.61	bob.brown@example.com	-1502745643	Good	1
26	EMP1025	David	Miller	NULL	Cloud Tech	Nevada	Pending	2020-04-30	66025.92	david.miller@example.com	-9485625727	Average	0
27	EMP1026	Frank	Miller	25	Sales	New York	Inactive	2023-10-02	83979.01	frank.miller@example.com	-7032032073	Average	0
28	EMP1027	Heidi	Johnson	30	Finance	Florida	Active	2020-07-12	NULL	heidi.johnson@example.com	NULL	Excellent	1
29	EMP1028	Grace	Garcia	40	Finance	Nevada	Active	2023-10-11	95741.88	grace.garcia@example.com	-7712151341	Excellent	0
30	EMP1029	Alice	Brown	40	DevOps	California	Active	2021-05-24	63411.31	alice.brown@example.com	-2849939088	Excellent	1

4) VERİ KALİTESİ ANALİZİ

Veri temizleme sürecinin etkinliğini ölçmek amacıyla çeşitli analizler yapılmıştır. Analizler bu scriptler ile gerçekleştirilmiştir: total_employee_counts.sql, problem_counts.sql, null_counts.sql

Bu analizler sayesinde “Kaç veri hatalıydı?”, “Hangi alanlarda sorun vardı?”, “Temizleme sonrası kaç değer NULL oldu?” gibi sorulara cevap üretilmeye çalışılmış.

	issue_type	issue_count
1	Invalid Age	300
2	Invalid Email	102
3	Invalid Salary	123
4	Invalid Join Date	102
5	Trim Needed In First_Name	102
6	Department Format Inconsistent	1020

	null_age	null_join_date	null_salary	null_email	null_phone
1	300	102	123	102	102

4) SONUÇ VE GENEL DEĞERLENDİRME

Bu projede, veri temizleme sürecinin veri analizi açısından ne kadar önemli olduğu uygulamalı olarak gösterilmiştir. Kirli verilerin doğrudan kullanılması hatalı sonuçlara yol açar, yapılan ETL işlemleri sayesinde veri daha güvenilir ve analiz edilebilir hale getirilmiştir.

Ayrıca bu projede; veri temizleme ve dönüşüm işlemlerinin dikkatli yapılması, orijinal verinin korunması gibi konulara da yer verilip önemli veri mühendisliği prensipleri uygulanmıştır.

